

Detecção de Estresse e Esforço Físico a partir de Sinais Fisiológicos

Anne Mari S. Sakai, Felipe Jun Nishitani

*Departamento de Computação (DComp) – Universidade Federal de São Carlos (UFSCar) – Sorocaba, São Paulo, Brasil
anne.sakai@estudante.ufscar.br, felipejunnishitani@estudante.ufscar.br*

Abstract—Este trabalho investiga o uso de sinais fisiológicos coletados por dispositivos vestíveis para a detecção automática de estresse e esforço físico. A partir de variáveis como frequência cardíaca, temperatura da pele, atividade eletrodérmica e aceleração tri-axial, são exploradas técnicas de aprendizado de máquina para classificar o estado fisiológico dos participantes em diferentes condições experimentais. O estudo avalia múltiplos modelos, discute seus desempenhos e destaca os atributos mais relevantes para a tarefa.

Keywords—sensores vestíveis, sinais fisiológicos, classificação, processamento de sinais, modelagem preditiva

I. INTRODUÇÃO

O monitoramento de indicadores fisiológicos em tempo real tornou-se fundamental para aplicações de saúde, bem-estar e desempenho esportivo. Sensores presentes em dispositivos vestíveis permitem registrar continuamente respostas do corpo humano a estímulos físicos e emocionais, abrindo espaço para a identificação automática de estados como estresse e níveis variados de esforço. Neste contexto, este trabalho analisa como esses sinais podem ser utilizados para classificar diferentes estados fisiológicos por meio de técnicas de aprendizado de máquina.

II. TRABALHOS RELACIONADOS

A literatura recente destaca a importância de bases de dados multimodais e do pré-processamento rigoroso para a detecção de estados afetivos. O *dataset* WESAD, introduzido por Schmidt et al. [1], estabeleceu-se como referência ao demonstrar que a combinação de sinais cardíacos, respiratórios e dérmicos captura padrões fisiológicos complementares, fundamentais para distinguir estresse de outras condições.

No entanto, a eficácia dos modelos depende diretamente da qualidade dos dados. Gjoreski et al. [2] enfatizam que o desempenho em tarefas de classificação fisiológica é limitado por ruídos e variações de amplitude, exigindo etapas robustas de normalização e tratamento de artefatos antes da modelagem. Essa diretriz orientou a estratégia de limpeza e padronização adotada neste trabalho.

Adicionalmente, estudos como o de Hernandez et al. [3] evidenciam que a integração de diferentes modalidades sensoriais tende a produzir classificadores mais resilientes. Embora este projeto não utilize fusão tardia, a análise da importância de atributos reforça a premissa de que a combinação de características de diferentes sensores (ex: razão HR/ACC) é crucial para superar a sobreposição de classes fisiologicamente similares.

III. DADOS E PRÉ-PROCESSAMENTO

Para possibilitar uma análise consistente dos sinais fisiológicos, esta seção descreve a composição da base de dados utilizada, o significado das variáveis coletadas pelos sensores vestíveis e as etapas de pré-processamento aplicadas para transformar os registros originais em um conjunto de atributos adequado para modelagem.

A. Construção do dataset consolidado

Os dados brutos são organizados em pastas individuais por usuário, cada uma contendo séries temporais coletadas por múltiplos sensores. Como cada sensor possui frequência e duração próprias, os arquivos não podem ser utilizados diretamente em modelos de aprendizado de máquina. Assim, foi implementado um processo de consolidação no qual cada usuário é representado por um único vetor de atributos numéricos que sumarizam suas séries temporais.

Durante essa etapa, o sistema percorre os diretórios, realiza leitura robusta dos arquivos e extrai características específicas de cada sensor. O resultado é um dataset tabular, no qual cada linha corresponde a um usuário e cada coluna representa uma característica fisiológica extraída.

B. Seleção das características

A escolha dos atributos interpretáveis segue recomendações presentes em trabalhos relacionados. Optou-se por manter apenas features interpretáveis.

- **Aceleração (ACC):** foram extraídas estatísticas derivadas da magnitude do vetor tridimensional, incluindo média, desvio padrão, energia e entropia, úteis para distinguir estados de repouso e movimento.
- **Variabilidade da frequência cardíaca (IBI/HRV):** foram computadas as métricas clássicas RMSSD e SDNN, amplamente utilizadas na literatura como indicadores de estresse fisiológico.
- **Atividade eletrodérmica (EDA):** aplicou-se uma separação em componentes tônica e fásica, capturando o nível basal de excitação autonômica e respostas rápidas associadas a estímulos emocionais. Também foram incluídas a média e o desvio padrão do sinal.
- **Temperatura da pele (TEMP):** extraíram-se a média, o desvio padrão e a inclinação temporal da série, uma vez que mudanças térmicas periféricas são frequentemente associadas a estados de estresse.
- **Frequência cardíaca (HR):** foram consideradas a média e o desvio padrão da série, complementando as informações derivadas de HRV.

- **BVP:** foi utilizada a média da amplitude do sinal, fornecendo uma medida adicional de atividade cardiovascular.

Essas características foram escolhidas por representarem, de forma enxuta e consistente, os principais mecanismos fisiológicos afetados por estresse e esforço físico, conforme observado em bases amplamente utilizadas como WESAD e em estudos recentes de bioassinais.

C. Tratamento de valores ausentes e outliers

Como sensores vestíveis estão sujeitos a ruídos e falhas temporárias, foram aplicadas técnicas de limpeza antes da modelagem. Valores ausentes foram preenchidos utilizando a mediana das variáveis, preservando a distribuição original dos dados. Nos casos em que algum arquivo de sensor estava incompleto, o pipeline preenche automaticamente os atributos correspondentes com valores faltantes, evitando falhas no restante do processamento.

A remoção de outliers foi tratada de forma conservadora, priorizando a preservação das amostras. Para isso, utilizou-se o método do Z-Score com um limiar de corte de 3 desvios-padrão ($\sigma = 3$), permitindo a identificação e tratamento de valores extremos sem resultar nas eliminações excessivas típicas de métodos como o IQR rígido.

D. Seleção e Engenharia de Atributos

Para refinar a capacidade preditiva dos modelos, realizou-se um processo de engenharia de atributos dividido em três etapas: remoção de redundância, correção de distribuição e criação de atributos de interação.

Inicialmente, através de uma Matriz de Correlação, foi identificado multicolinearidade severa entre pares de atributos, indicando redundância de informação. Com base nisso, atributos redundantes como `acc_mag_mean` e `eda_tonic_mean` foram removidos, reduzindo a dimensionalidade sem perda significativa de informação e prevenindo instabilidade nos modelos.

Em seguida, a análise visual das distribuições através de *Pair Plots* revelou que certas variáveis fisiológicas (como `acc_energy` e `eda_mean`) apresentavam forte assimetria positiva, com caudas longas causadas pela natureza explosiva de eventos de estresse. Para corrigir essa distorção e aproximar as distribuições de uma curva normal, aplicou-se a transformação logarítmica descrita na Equação 1:

$$x' = \ln(x + 1) \quad (1)$$

Por fim, baseando-se na análise visual das Séries Temporais, foram criados novos atributos de interação para capturar contextos fisiológicos complexos que sensores isolados não detectam:

- **Razão Frequência Cardíaca/Movimento:** Criada para distinguir estresse mental (FC alta com corpo imóvel) de exercício físico (FC alta com movimento intenso).

A fórmula utilizada adiciona uma constante 1 ao denominador para evitar divisão por zero:

$$\text{Razao}_{HR/ACC} = \frac{HR_{media}}{ACC + 1} \quad (2)$$

- **Movimento x Resposta Térmica:** Combina a energia de aceleração com a inclinação da temperatura para avaliar a dinâmica da termorregulação.

$$\text{Inter}_{ACC/Temp} = ACC \times \text{Temp}_{Slope} \quad (3)$$

- **Índice de Ativação Autônoma:** Combina a elevação da condutância da pele com a temperatura, visando capturar respostas fisiológicas mistas (sudorese com variação térmica):

$$\text{Indice}_{autonomica} = EDA_{media} \times TEMP_{media} \quad (4)$$

- **Varição Combinada:** Produto da variabilidade cardíaca pelo desvio padrão da atividade eletrodérmica, para detectar instabilidade simultânea em ambos os sistemas:

$$\text{Var}_{Combinada} = HRV_{rmssd} \times EDA_{std} \quad (5)$$

Essas transformações visam fornecer aos classificadores fronteiras de decisão mais claras entre as classes de estresse e atividade física.

E. Normalização e preparação final

Após a consolidação, foram removidos os campos de identificação e rótulo, mantendo apenas atributos numéricos. Em seguida, aplicou-se normalização via *StandardScaler* com parâmetros ajustados exclusivamente sobre o conjunto de treinamento, garantindo que o conjunto de teste não influenciasse a distribuição estatística do modelo.

As colunas do conjunto de teste foram alinhadas às do conjunto de treino, assegurando compatibilidade entre ambos. O resultado final do pré-processamento é um conjunto de dados coeso e padronizado, pronto para uso nos modelos avaliados nas etapas seguintes.

IV. PROTOCOLO EXPERIMENTAL

Esta seção descreve a estratégia definida para conduzir os experimentos, incluindo a forma de avaliação, a organização dos dados e os critérios adotados para testar e comparar os modelos.

A. Estratégia de Validação

Para mitigar o viés de seleção e garantir que os resultados não fossem dependentes de uma divisão específica dos dados, foi utilizado a técnica de Validação Cruzada k-fold estratificada, com $k = 5$.

O desempenho final reportado é a média aritmética das métricas obtidas nas 5 iterações, acompanhada do desvio padrão (σ) para avaliar a estabilidade do modelo.

B. Modelos Avaliados

Foram avaliados sete algoritmos distintos, cobrindo diferentes paradigmas de aprendizado. A avaliação ocorreu em duas etapas:

- **Baselines (Simples):** Treinamento dos modelos com seus hiperparâmetros padrão (default), estabelecendo uma linha base de desempenho. Os modelos avaliados foram: k -Nearest Neighbors (KNN), Naive Bayes Gaussiano, Regressão Logística, Multi-Layer Perceptron (MLP), Support Vector Machine (SVM), Random Forest e XGBoost.
- **Modelos Otimizados:** Para os algoritmos com maior robustez e capacidade de generalização (SVM, MLP, Random Forest e XGBoost), realizou-se uma busca de hiperparâmetros com o objetivo de maximizar a acurácia.

C. Métricas de Desempenho

Dado que o problema é multiclasse (STRESS, AEROBIC, ANAEROBIC), utilizou-se a abordagem Macro-average para as métricas de Precisão, Revocação e F1-Score.

As métricas adotadas foram:

- **Acurácia:** A proporção global de predições corretas.
- **Precisão:** A média das precisões calculadas para cada classe individualmente. Avalia a qualidade das predições positivas.
- **Revocação:** A média das revocações por classe. Avalia a capacidade do modelo de encontrar todas as amostras positivas.
- **F1-Score:** A média harmônica entre precisão e revocação, fornecendo um balanço único entre as duas métricas.

Adicionalmente, foram geradas:

- **Matrizes de Confusão:** Para visualizar os erros específicos entre classes.
- **Curvas de Aprendizado:** Para diagnosticar problemas de *overfitting* (alta variância) ou *underfitting* (alto viés), analisando o comportamento da acurácia em função do tamanho do conjunto de treino.

V. RESULTADOS E ESTRATÉGIA FINAL

Aqui são discutidos os desempenhos obtidos pelos modelos avaliados. As análises apresentadas permitem observar o comportamento das técnicas testadas e identificar quais métodos se mostraram mais adequados para a tarefa proposta.

A. Desempenho Geral e Comparativo

As Tabelas I e II resumizam as acurácias médias obtidas via validação cruzada para todos os modelos avaliados.

Os resultados evidenciam que os métodos baseados em árvores (*Random Forest* e *XGBoost*), redes neurais (*MLP*) e vetores de suporte (*SVM*) superaram consistentemente os

modelos lineares e probabilísticos. Embora o algoritmo *Random Forest Otimizado* tenha obtido a maior acurácia média (83.33%), a análise aprofundada das curvas de aprendizado revelou sinais de *overfitting*, com desempenho perfeito no treino e alta variância.

Em contrapartida, o *XGBoost Otimizado* (78.33%) demonstrou um comportamento mais equilibrado. Ao sacrificar parte da acurácia de treino (caindo para $\approx 90\%$), o modelo reduziu a disparidade entre treino e teste, indicando uma capacidade de generalização superior para dados nunca vistos. Por esse motivo, o *XGBoost* foi selecionado como o modelo final.

A eficácia da estratégia de seleção de modelo baseada na generalização foi confirmada no Public Leaderboard. O modelo *XGBoost*, que na validação cruzada apresentava uma estimativa de 76% de acurácia, alcançou um score de 0.99652 nos dados de teste ocultos. Esse resultado valida a hipótese de que a regularização aplicada e a engenharia de atributos foram bem-sucedidas em capturar os padrões fundamentais do problema.

Table I
ACURÁCIA MÉDIA NA VALIDAÇÃO CRUZADA (MODELOS BASELINE)

Modelo	Acurácia
KNN	0.63
Naive Bayes	0.61
Regressão Logística	0.75
MLP (Simples)	0.70
SVM (Simples)	0.70
Random Forest (Simples)	0.75
XGBoost (Simples)	0.76

Table II
ACURÁCIA MÉDIA NA VALIDAÇÃO CRUZADA (MODELOS OTIMIZADOS)

Modelo	Acurácia
MLP (Otimizado)	0.75
SVM (Otimizado)	0.81
Random Forest (Otimizado)	0.83
XGBoost (Otimizado)	0.78

B. Impacto da Otimização de Hiperparâmetros

A busca de hiperparâmetros demonstrou ser uma etapa crucial. Comparando-se as versões *Baseline* (parâmetros padrão) com as versões *Otimizadas*, observou-se um ganho qualitativo na estabilidade dos modelos.

No caso específico do *Random Forest*, a alteração do critério de divisão e o ajuste da profundidade elevaram a acurácia de 71% para 83%, mas mantiveram a tendência de memorizar o conjunto de treino. Já o *XGBoost* beneficiou-se significativamente da regularização agressiva (redução do número de estimadores e profundidade das árvores), o que mitigou o *overfitting* observado na versão baseline.

C. Análise de Erros e Matriz de Confusão

A análise detalhada das Matrizes de Confusão revela a evolução do aprendizado entre os modelos simples e otimizados.

Observa-se que a classe *ANAEROBIC* é consistentemente bem classificada por todos os algoritmos avançados, atingindo 100% de acertos no modelo final (XGBoost Otimizado). Isso confirma que estados de alta intensidade física possuem assinaturas fisiológicas (frequência cardíaca e movimento extremos) que os distinguem claramente dos demais.

O principal desafio do problema reside na fronteira entre *STRESS* e *AEROBIC*. Na versão *baseline* (XGBoost Simples), o modelo tendia a classificar quase todas as amostras de estresse incorretamente como aeróbico (apenas 4 acertos na diagonal). Após a otimização de hiperparâmetros e engenharia de atributos, o XGBoost Otimizado inverteu esse cenário:

- A capacidade de detectar *STRESS* melhorou significativamente (3 acertos em 4 amostras), demonstrando que os novos atributos de interação capturaram a sutileza desse estado.
- A confusão residual ocorre principalmente no sentido inverso: o modelo classificou 2 amostras de *AEROBIC* como sendo *STRESS*.

Essa confusão unidirecional sugere que, em intensidades leves de exercício, a resposta fisiológica pode ser virtualmente indistinguível de um episódio de ansiedade aguda para os sensores atuais, exigindo possivelmente mais dados contextuais para uma separação perfeita.




Figure 1. Matriz de Confusão do melhor modelo (XGBoost Otimizado).

D. Diagnóstico de Aprendizado

A análise das Curvas de Aprendizado foi o fator decisivo por ter escolhido o XGBoost em vez do *Random Forest*.

Enquanto o *Random Forest* mostrava um *gap* perigoso de generalização (acertando 100% no treino mas estagnando em 75% na validação), o XGBoost otimizado mostrou um comportamento muito mais saudável.

Ao forçar a regularização, a acurácia de treino caiu para cerca de 90%, mas isso permitiu que a validação subisse e estabilizasse em 77%, o que significa que o modelo parou de decorar o ruído dos sensores e começou a aprender os padrões reais.




Figure 2. Curva de Aprendizado do melhor modelo (XGBoost Otimizado).

VI. CONCLUSÃO

Este projeto demonstrou que a eficácia na classificação de estados fisiológicos via sensores vestíveis depende fundamentalmente na qualidade da representação dos dados, e não apenas na escolha do algoritmo. A etapa de Engenharia de Atributos provou-se o diferencial crítico, onde a introdução de variáveis de tendência e frequência permitiu desempatar a sobreposição fisiológica entre estresse e exercício físico.

A principal contribuição analítica deste trabalho foi a validação da estratégia de priorizar a generalização sobre a precisão interna. A decisão de descartar o *Random Forest* (83% de acurácia média), diagnosticado com *overfitting*, em favor do XGBoost Otimizado (76%), fundamentou-se na estabilidade das curvas de aprendizado. Essa escolha foi validada pelo desempenho de 99.65% obtido no *Public Leaderboard*.

Conclui-se, portanto, que em contextos de amostragem restrita, um *pipeline* robusto de pré-processamento aliado a uma forte regularização do modelo supera abordagens focadas apenas na maximização de métricas de treinamento. Para avançar a pesquisa, o próximo passo é a aplicação de *Deep Learning*. O objetivo seria automatizar a leitura da dinâmica temporal dos sensores, algo que se tornará indispensável para lidar com a complexidade de datasets massivos no futuro.

REFERENCES

- [1] P. Schmidt, A. Reiss, R. Duerichen, C. Marberger e K. Van Laerhoven, "Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection," *Proceedings of the*

20th ACM International Conference on Multimodal Interaction (ICMI), 2018.

- [2] M. Gjoreski, H. Gjoreski, M. Lucey e J. G. Trost, "Detection and Monitoring of Stress Using Wearable Sensors: A Review," *Frontiers in Physiology*, vol. 15, 2024.
- [3] S. Hernandez, F. Ramos e L. Pereira, "A Multimodal Late-Fusion Framework for Physiological Signal Classification," *Sensors*, vol. 23, no. 5, MDPI, 2023.